22

22. ТЗ: дерево SEO-страниц портала (генерация, сравнения, геопривязка)

Актуально на 12.11.2026. Версия 1. Поток 2 (воронка); к потоку 1 не относится. Собрано по промпту docs/prompts/seo-page-tree-tz.md.

Источники. vault/portal-filters/dev-filters-schema.md (код портала на 12.11.2026, обозначение ДС); vault/portal-filters/filters-comparison.md, filters-vs-dev-tree.md; vault/seo-benchmark/page-structure.md, comparison-table.md (бенчмарк, БМ); seo-platform/01-model-ia.md, 02-pseo.md, 04-product.md, 05-tech.md (прежние решения, июль 2026, данные РФ, ПС); docs/05, docs/10, docs/12; указания владельца от 12.11.2026 (ВЛ); работа четырёх независимых проверяющих по ролям (АГ: поиск, данные, сравнения, разработка). Базы портала у автора нет: объёмы даны формулами и запросом (приложение Г).

Разметка статусов. Ф — факт из входа; О — оценка стороннего сервиса; В — вывод; П — предложение (значение по умолчанию, вносится в открытые решения); Г — гипотеза. Каждое требование имеет код R-раздел.номер и источник. «Ист.» — код источника из списка выше или П.

Как читать. Разработчик — разделы 2–12, 14, приложения. Владелец — разделы 1, 13, 15, 16.

---

1. Решения и сравнение источников

1.1 Решения владельца от 12.11.2026 (устные)

№	Решение	Как учтено	Статус
ВЛ-1	Место правды — портал Сергея; второй базы нет	Все страницы строятся из его данных (раздел 3); внешние данные хранятся отдельными слоями с источником	принято
ВЛ-2	Добавить «Короткие программы» (в дереве Сергея нет, в концепте есть)	Новая сущность T11, раздел 3.2	принято; сущность в базе отсутствует (Ф)
ВЛ-3	Страницы сравнения «чисто под SEO»; потенциал «миллиард страниц»	Раздел 7. Миллиард не следует из входов (см. 5.4): это **Г**, решения на ней не строятся	принято частично
ВЛ-4	Дерево возможных страниц, включая не существующие (образец — Авиасейлс)	Три состояния существования, раздел 2.3; оболочка, раздел 6.3	принято
ВЛ-5	Блоки — «из букинг-сервисов»	Берётся состав блоков и логика; данные и тексты не берутся (раздел 6, 10)	принято с ограничением по лицензии
ВЛ-6	Геопривязка: достопримечательности, улицы, регионы; на вырост, модель сейчас	Раздел 8; генерация по этапам (раздел 13)	принято
ВЛ-11 (13.11.2026)	Режим контента распространяется на все типы страниц, включая вуз, колледж, школу, программу: в индексе они выглядят так, а подбор по своим параметрам пользователь делает поиском. Для уникализации владелец передаёт матрицу параметров с весами по типам страниц	R-4.4.9, R-4.4.10; матрица ещё не получена	принято; ждёт матрицу
ВЛ-10 (13.11.2026)	Страницы-маршруты как у Авиасейлс (/routes/{из}/{в}, /routes/{из}, /countries/{страна} с «в» и «из»): не выдают значений из базы по вузам и программам; уникальность — блоки текста; выдача строится после нажатия «Найти»; год набора отличается текстом	Раздел 4.4, режим контента	принято; риски раздела 4.4
ВЛ-9 (13.11.2026)	Локализация: сначала английская версия, затем русская; страницы сразу на двух языках	docs/24; R-9.10 уточнён: основной язык — английский, x-default = en	принято
ВЛ-8 (13.11.2026)	Страницы из поиска не привязаны к пользователю: адрес формируется из выбранных параметров фильтра, открыт всем, включая роботов	Тип T43, раздел 4.3	принято с условиями: пороги и канонизация обязательны
ВЛ-7	Подборки сравнений из выбора пользователей (лайки, закладки), наборы 3–5, в том числе из разных городов и стран	Раздел 7.3. **Заблокировано до правового решения** по данным подростков (R-7.14)	принято, блокер

1.2 Противоречия с прежними документами (прежние файлы не изменены)

Тема	Прежнее решение (Ф)	Решение ВЛ / ограничение	Вердикт ТЗ
Индексация сравнений	seo-platform/04-product.md: страница сравнения noindex; 01-model-ia.md: /sravnenie/ не индексируется	ВЛ-3: сравнения для SEO	Индексируются **только** пары из белого списка (R-7.6). Остальное noindex. Прежнее правило отменяется для белого списка
Массовая генерация фасетов	02-pseo.md §2: «массовая генерация запрещена», кураторский слой ≈100–150	ВЛ-3, ВЛ-4: широкое дерево	Генерация разрешена как **создание адресов**; в индекс попадают только страницы, прошедшие пороги (раздел 5). Кураторский слой остаётся для наборов по фильтрам

Тема	Прежнее решение (Ф)	Решение ВЛ / ограничение	Вердикт ТЗ
Порог «≥ 2 вузов»	02-pseo.md: посчитан по вузам РФ, 79 % комбинаций отсечено	Новые типы без порогов	Порог переносится как умолчание для комбинаций; для остальных типов задан заново (5.2), калибруется по показам
Размер сравнения	04-product.md: до 4 вузов	ВЛ-7: наборы 3–5	5 (R-7.1)
Хранение выбора	04-product.md, 01-model-ia.md, docs/05 п.1: избранное и сравнение только в браузере; ПДн не собираются; кабинета нет	ВЛ-7: агрегат выбора пользователей требует сервера	Прямое противоречие. Подборки (вид в) не включаются до решения юриста (R-7.14). Виды а и б не затрагивают ПДн
Закрытие параметров в robots.txt	02-pseo.md §3: параметры не закрывать, иначе не виден noindex; Skyscanner (Disallow) и Aviasales (Clean-param) закрывают (БМ §3); БМ §9 п.4 рекомендует их схему; у Booking параметры не проверялись (БМ §10)	—	Берём правило 02-pseo: noindex + canonical; robots только для служебных путей и меток (R-9.8). Расхождение с рекомендацией БМ сознательное: закрытый в robots URL может остаться в индексе по внешним ссылкам (П; у Aviasales в Google в 6 раз больше страниц, чем в sitemap, причина не установлена, БМ §1) — основанием служит не это наблюдение, а логика 02-pseo
Стек	05-tech.md: выбран Astro, Rust+HTMX — путь отхода	Код портала уже на Rust (browse.rs, HTMX-обработчики, ДС §2, §8)	Основание выбора устарело; ТЗ исходит из Rust (R-11.1)
lastmod	02-pseo.md §6: дата принятия снимка для всех	Единая дата на миллионах URL поисковик игнорирует (П)	lastmod — дата изменения хэша данных страницы (R-9.7)
Внутренняя неясность	02-pseo.md §6: «404 не отдаём … 302? Нет: 200 с noindex»	—	Итог 200 + noindex, принят

1.3 Ограничения лицензий и поисковиков

- Booking, Skyscanner, Aviasales — образец состава блоков, не источник. Не копируются тексты, цены, отзывы, фото, списки объектов из их sitemap и страниц, структура их тематических подборок как набор данных. Партнёрские API — только на условиях договора, данные в портал не копируются (П: общее знание, сверить с условиями на дату запуска).
- Число URL в sitemap не равно числу страниц в индексе (Aviasales: 131 502 URL в sitemap, ≈ 796 тыс. в Google, О, БМ §1). Все оценки ниже — потолок или ставка.
- Массовый малоценный контент наказуем. Для каждого типа заданы порог индексации, правило тонкой страницы и порядок снятия (разделы 5, 9).
- Названия BFAS/Big Five и RIASEC в адресах и текстах не используются. Параметр riasec в ДС §5B (/careers?riasec=S) — публичный: его нужно переименовать (решение О-10), в подписях и текстах уже используются рабочие названия («с людьми», «с техникой» и т. д.).

2. Принципы

R-2.1 Страница — это уникальный адрес, который отдаёт ответ 200 с собственным заголовком, текстом и набором данных. Состояние поисковой выдачи (/find?...) страницей для поиска не является (ДС §3.1: noindex, follow, canonical /find). Ист.: ДС.

R-2.2 Ценность страницы = то, что посетитель не получит со страницы родителя и соседа: свой набор программ или вузов, свои агрегаты, своё сравнение, своя геопривязка. Нет такой разницы — страница не индексируется (R-2.5). Ист.: ПС §2 (довод о дубле и каннибализации), П.

2.3 Три состояния существования

Состояние	Условие	Ответ	В sitemap	В перелинковке
Материализована	Данные есть и пороги раздела 5 выполнены	200, index	да	да
Оболочка	Все сущности адреса существуют, пара допущена (allowed_pair), но данных меньше порога	200, noindex, follow, canonical на себя	нет	только из форм и подборок «ближайшее»
Не создаётся	Любая сущность адреса не существует, адрес вне допущенного графа или не прошёл нормализацию	404 (или 301 на канонический)	нет	нет

R-2.4 Каждая страница в каждый момент находится ровно в одном состоянии; решение принимает функция от данных, без ручных исключений (кроме белых списков, раздел 7). Критерий: тест «одни данные — одно состояние». Ист.: АГ-разработка, П.

R-2.5 Правило тонкой страницы. Если страница не проходит пороги индексации: (1) все сущности адреса существуют — страница остаётся живой как оболочка (noindex, canonical на себя); (2) страница, которая по составу данных совпадает с родителем (например, единственный вуз города), не создаётся как отдельная и получает canonical на родителя; (3) сущности нет — не создавать (404). Пороги относятся к **индексации**, а не к созданию адреса. Вход в индекс — после H = 2 подряд пересборок с выполненными порогами; выход из индекса (понижающий гистерезис) — после двух подряд пересборок ниже порога (П).

Соответствие слоёв. «Существование» (раздел 2.3) и «индексация» независимы: материализованная страница может быть noindex (пары сравнения вне белого списка — материализованы, класс B, noindex); «оболочка» и «класс C» — одно и то же. Ист.: ПС §6, АГ-SEO.

R-2.6 Оболочка отвечает 200, а не 404: она полезна посетителю (6.3). Риск soft 404 снимается тем, что она не в sitemap, имеет noindex и показывает реальные факты, а не заглушку. Ист.: ВЛ-4; риск — АГ.

3. Сущности и справочники

3.1 Из портала Сергея (Ф, по ДС)

Код	Сущность	Адрес в портале сейчас	Ключевые поля из ДС
E01	Страна	/countries/{cc}, /universities/{cc}	ISO-код, рынок, валюта, календарь сроков, фильтры страны
E02	Город	/universities/{cc}/{город}, to=cc/город	страна, слаг
E03	Вуз / E04 колледж	/universities/…, /colleges/…	финансирование, цена, страновые поля
E05	Программа	страниц нет в разобранных файлах (пробел), карточки в /find	уровень, язык, форма, цена, срок, длительность, проходной балл, бюджетные места, места для иностранцев
E06	Направление	/fields/{slug}	семейства CIP, сфера
E07	Сфера	/spheres/{slug}	slug
E08	Профессия	/careers/{slug}	тип работы, медиана зарплаты, риск ИИ, «хватит колледжа»
E09	Олимпиада	/olympiads (только ru)	предмет, уровень, класс, вид льготы
E10	Подборка редактора	/collections/{slug}	—

Адреса слагов: транслитерация + идентификатор (seo-platform/01-model-ia.md В3). Языки интерфейса: ru, en в первом выпуске; kk, uz, ar — по готовности перевода (R-9.10). Ист.: ПС.

3.2 Новые сущности (отсутствуют в базе, Ф)

Общие поля новых сущностей: id, slug, country_iso2, names{ru,en,ar,kk,uz} с признаком «ручной / машинный», lat, lon, status, и для каждой записи source, source_id, fetched_at, license. Внешние идентификаторы: wikidata_qid, osm_id, geonames_id. Ист.: АГ-данные (П).

Код	Сущность	Минимальные поля сверх общих
E11	**Короткая программа** (ВЛ-2)	provider_org_id, format (очно / онлайн / смешанно), topic_id, duration_days, age_min, age_max, price, currency, start_date, end_date, language, city_id. Без age_min, age_max, start_date страница не индексируется
E12	**Школа**	type (государственная / частная / международная), curriculum, age_range, boarding, city_id, site
E13	Достопримечательность	kind, city_id (может быть пусто), popularity_score, centroid
E14	Улица / район	kind, parent_id, centroid, bbox (геометрию храним только как центроид и прямоугольник)
E15	Природный регион	kind=natural, bbox, связь с несколькими странами
E16	Набор сравнения	kind (a/b/c), entity_type, ids[] в каноническом порядке, source (кураторский / фильтр / агрегат), state, n_support (только для вида в)

R-3.1 Любая запись внешнего происхождения содержит четыре поля происхождения; просроченная по fetched_at запись помечается, а не удаляется. Критерий: запрос «записи без license» возвращает 0. Ист.: правило данных CLAUDE.md.

R-3.2 Данные OpenStreetMap хранятся отдельным слоем, без слияния полей с основной базой (лицензия ODbL требует share-alike для производной базы; П — нужна проверка юриста до запуска). Ист.: АГ-данные.

R-3.3 Школы и короткие программы по MENA: проверенных открытых реестров в источниках нет (пробел). Источник — загрузка провайдерами и ручная курация; до проверки noindex. Ист.: docs/12 (по MENA только рынок AE), АГ.

4. Грамматика страниц и дерево типов

страница = тип + слоты сущностей + слоты фасетов + слоты геопривязки (+ язык)

Слоты: сущность (E01–E16), фасет (уровень, язык, форма, бюджет-ступень, возраст, период, тема), геообъект (E13–E15). Фасет в индексируемом адресе — **не более одного** значения на фасет и не более одного фасета на тип, кроме явно перечисленных в приложении А (R-4.1, П; согласуется с ПС §3).

```mermaid
flowchart TB
R["Справочные<br/>T01–T11"] --> C["Комбинации<br/>T20–T27"]
R --> M["Маршруты-оболочки<br/>T30"]
R --> S["Сравнения<br/>T40–T42"]
R --> G["Геостраницы<br/>T50–T54"]
C --> S
G --> C
M -. "после порога" .-> C
Q["/find?... (выдача)"] -. "noindex, canonical /find" .- C
```

R-4.2 Канонизация адреса. Ключи фасетов по алфавиту, значения отсортированы, дубли убраны; неканонический адрес → 301 на канонический. Неизвестное значение → 404 без обращения к базе (проверка по множеству сущностей в памяти). Для наборов — идентификаторы по возрастанию. Ист.: ДС §3.1 (404 на неизвестное), АГ.

4.3 Страницы из выбранных фильтров (T43)

Решение владельца ВЛ-8 (13.11.2026): результат поиска получает постоянный публичный адрес, который строится только из выбранных параметров, без привязки к пользователю. Это не подборка из лайков (T42, вид в): здесь нет голосов, учётных записей и агрегатов поведения.

Код	Требование	Критерий	Ист.
R-4.3.1	Адрес — путь с фиксированным порядком сегментов: страна, город, направление, уровень, язык, форма, условие. Шаблон /{lang}/р/{cc}[/{город}]/{направление}/{уровень}/{язык}/{форма}/{условие}/{набор}, пустые сегменты опускаются; {набор} — год набора (2027, 2028) (П). Параметры запроса в канонический адрес не входят	одно множество фильтров — один адрес	ВЛ-8, П
R-4.3.2	Допустимые фасеты и значения: направление, уровень, язык, форма, условие «бесплатно», год набора; по одному значению на фасет (мультивыбор «ИЛИ» из ДС §8.1 постоянного адреса не получает); бюджет — только ступени (Т25); не входят: from, месяц when, now, near, sort, page, price_min, price_max, unpriced, q	неподходящая комбинация остаётся /find, noindex	ДС §3, П
R-4.3.3	Допустимые наборы фасетов (белый перечень, потолок 4 фасета): страна+направление; страна+уровень; страна+язык; страна+направление+уровень; страна+направление+язык; страна+направление+уровень+язык; страна+направление+уровень+условие «бесплатно»; город+направление. Остальные наборы не получают адреса. **Год набора** добавляется к любому из перечисленных наборов при условии R-4.3.9	автотест на перечень	П, ВЛ-8
R-4.3.9	**Год набора как фасет.** Страница с годом создаётся в режиме контента (раздел 4.4): год отличает её текстом (календарь подготовки с датами года, блоки по сроку), а не списком программ. Условие индексации — R-4.4.5 (доля общих предложений с соседями) и R-4.4.6 (пробная выборка). Прежнее условие «список должен различаться» отменено решением ВЛ-10	см. R-4.4.5	ВЛ-10
R-4.3.10	**Перемножение.** Для каждой пары (направление, страна) создаются страницы по всем комбинациям значений фасетов из R-4.3.3 с порогами раздела 5. При n_i значений у k фасетов число адресов пары равно $\prod(1 + n_i)$ (включая базовую страницу без фасетов). Пример: язык 2 × уровень 2 × год 2 → $3 \cdot 3 \cdot 3 = 27$ адресов на пару (направление, страна), из них индексируемых — только прошедшие пороги	формула в запросе приложения Г	ВЛ-8
R-4.3.4	Адрес существует (200) для любой допустимой комбинации, не привязан к пользователю и одинаков для людей и роботов; индексируется только при выполненных порогах раздела 5 (P_prog, P_inst, K_blocks, U_facts, U_text); иначе оболочка noindex (R-2.5)	один ответ для всех	ВЛ-8, П
R-4.3.5	Если комбинация совпадает с типом Т20–Т26, используется адрес и шаблон этого типа, а не Т43 (нет двух адресов для одного набора)	0 дублей	П
R-4.3.6	Связь с выдачей: /find?… остаётся интерфейсом поиска (noindex, follow, ДС §3.1). Кнопка «Поделиться» и ссылка «Открыть страницей» ведут на постоянный адрес. Автоматический 301 с /find?… на постоянный адрес (для всех GET без JS) — решение О-11	—	П
R-4.3.7	Мета: шаблон Т43 из docs/23 §4.3	автотест М-А1	docs/23
R-4.3.8	Защита от взрыва: число адресов ограничено белым перечнем и порогами; ссылки на комбинации ниже порога не размещаются во внутренней перелинковке; запрос несуществующего значения фасета → 404 без обращения к базе (R-11.7)	—	АГ-разработка

Оценка объёма: Σ по допустимым наборам $\prod$ N_значений фасетов, затем фильтр порогами; в таблице приложения Г считается отдельной строкой Т43.

4.4 Режим контента: страницы-маршруты без значений из базы (ВЛ-10)

Образцы Авиасейлс (/routes/TOF/KJA, /routes/mow/ayt, /routes/mow/led, /routes/pez, /countries/italiya): страница-узел маршрута; у конкурента на ней есть цены и расписание, у портала их заменяют уникальные блоки текста, а результаты поиска строятся после нажатия «Найти». Образцы: docs/html/seo-samples/{en,ru}/routes-kz.html, route-kz-de.html, countries-it.html, route-de-it-*.html (8 страниц).

Иерархия (аналог Авиасейлс).

Тип	Адрес	Аналог	Что даёт уникальность
T31 хаб страны отправления	/{lang}/from/{cc}	/routes/pez	признание документов, визы и подтверждение средств для абитуриентов из этой страны; как сравнивать страны
T30 маршрут «из X в Y»	/{lang}/from/{cc}/to/{cc}	/routes/mow/led	допуск, виза, средства для пары стран; выбор пути (ссылки ниже)
T43 пара + фасеты	/{lang}/from/{cc}/to/{cc}/{направление}/{уровень}/{язык}/{год}	детализация маршрута	поступление по уровню, язык, календарь года, документы, направление, FAQ
T01 страна с «в» и «из»	/{lang}/countries/{cc}	/countries/italiya	вкладка «в страну»: поступление иностранца; вкладка «из страны»: учёба за рубежом для студентов этой страны

Страна отправления — фасет origin: без неё страницы строятся для «любой страны отправления»; с ней добавляются блоки о признании документов, визах и средствах. Это главный источник реально уникального текста.

Код	Требование	Критерий	Ист.
R-4.4.1	**Классы данных.** D0 (запрещены на странице режима контента): записи вузов и программ, любые числа, выведенные из базы (число программ, вузов, цены, баллы, проценты), списки названий программ и вузов. D1 (разрешены): справочники (названия, падежи, таксономия «направление ↔ профессия»), календарь стран, булево «в базе есть программы для комбинации». D2 (разрешены): редакционный текст с источником и датой	автотест: в HTML страницы режима контента нет строк из D0 (поиск по числам и названиям из базы)	ВЛ-10
R-4.4.2	**Создание.** Адрес создаётся, только если в базе есть программы для комбинации (булево allowed_pair); число не показывается. Страница, обещающая несуществующие программы, не создаётся (404)	тест на комбинацию без программ	ВЛ-10, П
R-4.4.3	**Выдача.** Кнопка «Найти» ведёт на /find (noindex, follow, ДС §3.1); значения фильтров переносятся из адреса. Список не входит в HTML страницы и в JSON-LD. Выдача защищена от выгрузки: лимит запросов на адрес, проверка ботов, глубина не более 1 000 записей (ДС §7)	в исходном HTML страницы нет карточек	ВЛ-10, ДС
R-4.4.4	**Блоки.** Обязательные: введение с фасетами, поиск, поступление по уровню, язык обучения, календарь набора (даты считаются от года), документы, направление (из таксономии), FAQ, ссылки на соседние версии. Для страниц с origin добавляются: признание документов, виза, подтверждение средств	K_blocks для режима контента считается по этому перечню (≥ 6 блоков)	П
R-4.4.5	**Уникальность.** Доля одинаковых предложений между страницей и каждой соседней (другой год, другой язык, другой уровень) не выше U_share = 40 % (отношение пересечения предложений к объединению, предложения ≥ 25 знаков). Страница выше порога — noindex либо canonical на родителя	автотест на выборке; **образцы этого T3 проверку не проходят: год 58 %, язык и уровень 67 % — требуется больше текста, зависящего от фасета**	П
R-4.4.6	**Год набора.** Если страницы разных лет различаются только датами, они не проходят R-4.4.5. Индексируются только годы с собственным содержанием (изменения правил, опубликованные сроки, календарь стипендий). До проверки — noindex либо canonical на страницу без года; пробная выборка 5 % на 60 дней	решение по доле индексации и показам	П
R-4.4.7	**Масштабная генерация текста.** Риск «дорвеев» и «масштабного малоценного контента»: страницы, различающиеся подстановкой слов, поисковики исключают. Тексты пишутся блоками по одному фасету (страна, уровень, язык, год, страна отправления), проверяются редактором, имеют источник с датой; машинная генерация без проверки не публикуется	отчёт редактора по блокам	П; docs/05, правило данных CLAUDE.md

Код	Требование	Критерий	Ист.
R-4.4.8	**Мета и разметка.** В режиме контента в title, description, OpenGraph и JSON-LD нет значений из базы (числа, цены): шаблоны — docs/23, раздел 4.7. FAQPage только по видимым вопросам	автотест M-A8	docs/23
R-4.4.9	**Все типы в режиме контента (ВЛ-11).** Страницы T01–T10 и T11, T12… показывают в HTML только данные классов D1 и D2 (R-4.4.1). Для страниц-сущностей (вуз, колледж, школа, программа) к D1 относятся данные, определяющие саму сущность: название, страна, город, тип, сайт, год основания, если есть. Не показываются: списки программ, числа программ и вузов, цены, баллы, проценты, места, сроки по конкретным программам. Подбор по параметрам — только через «Найти» (R-4.4.3). Уточнение границы D1 — решение O-16	автотест R-4.4.1 на всех типах	ВЛ-11
R-4.4.10	**Матрица параметров уникализации.** Владелец передаёт матрицу «параметр × тип страницы × вес». Параметры матрицы, доступные для вывода (не относящиеся к D0), становятся источниками блоков; вес задаёт порядок и обязательность блока и входит в расчёт «индекса уникальности» страницы наряду с R-4.4.5. Раздел заполняется после получения матрицы (в сессии 13.11.2026 страница матрицы закрыта паролем и недоступна)	матрица приложена к ТЗ, каждый её параметр отнесён к D0, D1 или D2	ВЛ-11

Полная таблица типов с адресами — приложение А.

5. Подсчёт объёма

5.1 Параметры (одно умолчание на параметр; всё П, калибруется по показам)

Параметр	Умолчание	Обоснование и как подбирать
P_inst **— мин. число вузов в комбинации**	2	перенос из 02-pseo (ПС)
P_prog **— мин. число программ для страны×направление, уровня×страны и аналогов; одновременно требуется ≥** P_inst **вузов (три программы одного вуза — дубль карточки вуза)**	3	поднять, если доля индексации шарда < 50 % через 60 дней
P_short **— мин. число актуальных коротких программ в комбинации T27**	2	аналогично
K_blocks **— мин. число блоков с данными из шести: B03, B04, B05, B07, B09, B13 (блоки B01, B10, B14 есть всегда и не считаются)**	4	у Aviasales аэропорт 4 блока, у Skyscanner 8–20 (БМ §4); для типов без B05 или B13 считается 4 из оставшихся пяти (П)
U_facts **— уникальных фактов, отличающих страницу от ступицы**	8	автотест на выборке 100 страниц по типу
U_text **— уникального текста**	300 знаков	за вычетом шаблонных фраз
k_pair **— соседей для пар сравнения**	5	число пар ≤ n·k вместо n(n−1)/2 (объединение направленных связей «ближайший к» даёт от n·k/2 до n·k пар)
N_agg **— независимых пользователей для подборки**	50	раздел 7.3
R_obj **— радиус вуз ↔ достопримечательность**	5 км; район 3 км; улица 1 км; город 30 км	природный регион — по прямоугольнику
G_min **— вузов в радиусе для геостраницы**	3	иначе канонизация на город

Параметр	Умолчание	Обоснование и как подбирать
S_shard **— URL в файле sitemap**	10 000	лимит протокола 50 000; малый шард даёт диагностику доли индексации (БМ: у Booking файлы по ≈ 49 990, но им диагностика не нужна)
C_pair **— потолок числа индексируемых пар типа**	равно числу индексируемых сущностей этого типа (в среднем одна пара на сущность)	защита от накрутки белого списка; пример: 1 785 индексируемых вузов → ≤ 1 785 индексируемых пар
U_share **— предельная доля одинаковых предложений между соседними страницами режима контента**	40 %	R-4.4.5; снижать, если доля индексации шарда < 50 %
N_shell_max **— потолок числа оболочек типа**	2 × число материализованных страниц типа	краулинг сотен тысяч оболочек с кодом 200 тратит бюджет обхода; оболочки сверх потолка не создаются (404)
H **— число пересборок подряд для входа в индекс**	2	гистерезис
W_age **— окно наблюдения после первой индексации**	90 дней	дальше нулевые показы → снятие (9.5)

5.2 Формулы по типам (N_* — размеры справочников, взять из запроса Г)

Тип	Возможных	Создаваемых (адрес живой)	Ожидаемо в индексе (доля — Г)
T01–T11 справочные	N_entity	все существующие	вузы, колледжи, школы, страны, города — все; программы, олимпиады — по порогу K_blocks
T20 направление×страна	N_field·N_country	пары с ≥ 1 программой (остальные — 404)	пары с ≥ P_prog программ и ≥ P_inst вузов, прошедшие U_facts, U_text
T21 направление×город	N_field·N_city	пары с ≥ 1 вузом	≥ P_inst вузов, затем как T20
T22 уровень×страна, T23 язык×страна	N_level·N_country, N_lang·N_country	≥ 1 программа	как T20
T24 форма×город	N_form·N_city	≥ 1	≥ P_inst и запросный спрос (9.6)
T25 бюджет до X × страна	N_band·N_country; X из фиксированных ступеней (5 ступеней, П), не произвольное число	≥ 1	как T20; малая доля
T26 профессия → где учиться	N_profession·N_country	≥ 1	как T20; малая доля
T27 короткие: тема×страна×период×возраст	N_topic·N_country·N_period·N_age	≥ 1 актуальная программа	≥ P_short; период в прошлом → снятие
T30 маршрут «откуда → куда»	N_from·N_to·N_field·N_level	пары в allowed_pair (оболочка)	порог T20 для страны назначения + U_text
T43 страница из фильтров	Σ_набор ∏ N_значений по R-4.3.3	допустимые наборы с ≥ 1 программой	пороги T20, затем U_text
T40 пара «A или B»	n(n−1)/2	≤ n·k_pair (материализованы, noindex)	белый список, ≤ C_pair
T41–T42 наборы, подборки	C(n,k)	кураторские / по порогу	см. 7
T50–T54 геостраницы	N_place·N_type	≥ G_min вузов в радиусе	малая доля

5.3 Пример на известных числах

- Пары вузов РФ: 1 785 вузов (ПС, 02-pseo.md) дают $n(n-1)/2 = 1\,592\,220$ возможных пар; при $k_pair = 5$ создаётся от $1\,785 \cdot 5/2 \approx 4\,463$ до $1\,785 \cdot 5 = 8\,925$ пар (в зависимости от взаимности «ближайших»); потолок — 8 925 (Ф+В, расчёт). Индексируемых — не более $C_pair = 1\,785$.
- Комбинации «направление×город» РФ: 20 565 возможных, 4 317 при $P_inst = 2$ (ПС).
- Маршруты: 9 рынков «откуда» (начало списка «Откуда» в архиве скриншотов: ОАЭ … Грузия, filters-comparison.md; в ДС числа нет — В) × 23 страны «куда» (сводка экрана архива, filters-comparison.md; не выгрузка) = 207 пар стран. С N_field направлений и N_level уровней возможных маршрутов $207 \cdot N_field \cdot N_level$; при $N_field = 50$, $N_level = 3$ (П, иллюстрация) — 31 050. Реальные N_field, N_level берутся запросом Г.
- Данные экрана: 390 467 программ, Германия 22 638 (скриншоты собственного портала по сводке, filters-comparison.md; не выгрузка, не проверено).

5.4 Проверка тезиса «миллиард страниц» (В)

- Миллиард достижим только перебором сочетаний: $C(1000, 5) \approx 8{,}25 \cdot 10^{12}$ наборов по пять. Такое число страниц — не объём ценности, а число сочетаний.
- Полная материализация миллиарда при 8 воркерах и 50 страницах/с на воркер занимает ≈ 29 суток (П, расчёт $T = N/(W \cdot r)$); при 10^6 страниц — ≈ 42 минуты.
- Ориентир конкурентов: Aviasales ≈ 0,13 млн URL в sitemap и ≈ 0,8 млн в Google (БМ §1); Booking — потолок ≈ 1,4 млрд (27 751 файл × 50 000; замерены лишь файлы по ≈ 49 990), но 392 из 443 индексов — тематические подборки, то есть ценность создаёт охват каталога и отзывы, которых у портала нет.
- **Вывод.** Потолок разумной программы: 10^5–10^6 созданных адресов, индексируемых — порядка 10^4–10^5 (Г, условие: достаточная наполненность справочников; перестанет быть верным при росте числа программ и стран на порядок). Решения принимаются по порогам, не по миллиарду.

6. Каталог блоков и состав страниц

6.1 Каталог блоков

Источник блока — только база портала, открытые данные с лицензией или собственный текст. Блоков, наполняемых копированием со страниц конкурентов, нет.

Код	Блок	Статика / динамика	Источник	Лицензия	Обновление	Пустое состояние	Микроразметка
B01	Хлебные крошки	статика	дерево адресов	своя	при пересборке	всегда есть	BreadcrumbList
B02	Заголовок и форма «подобрать» (поля виджета предзаполнены)	динамика	ДС §2	своя	живая	форма всегда	WebSite + SearchAction на главной
B03	Показатели (число программ, вузов, вилка цен, языки, ближайший срок подачи)	динамика	агрегаты базы	своя	импорт	блок скрыт, если < 2 показателей	—
B04	Витрина (до 24 карточек вузов, программ, школ)	динамика	база	своя	импорт	оболочка (6.3)	ItemList
B05	Сроки подачи по месяцам (календарь страны)	динамика	календарь страны (ДС §3.3)	своя	по календарю	«Сроки уточнит эксперт» (как в ДС)	—
B06	Динамика цен и сроков	динамика	**истории цен в источниках нет** (пробел, в ДС только курсы 72 ч)	—	—	блок не строится до накопления истории	—

Код	Блок	Статика / динамика	Источник	Лицензия	Обновление	Пустое состояние	Микроразметка
B07	FAQ (только вопросы, ответ на которые видимо стоит на странице и берётся из агрегатов)	динамика	агрегаты базы	своя	импорт	блок скрыт	FAQPage (польза ограничена, 9.9)
B08	Текст о месте (страна, город, объект)	статика	редакция портала; для гео — описание из Wikidata (CC0) как основа, не как итог	своя / CC0	по запросу	страница не индексируется, пока нет U_text	—
B09	Подборки и топы	динамика	подборки редактора (E10), агрегаты	своя	импорт	скрыт	ItemList
B10	Соседние сущности (перелинковка)	динамика	дерево, near	своя	пересборка	не менее 3 ссылок вверх и вбок	—
B11	Статьи журнала	динамика	журнал	своя	—	**журнала в источниках нет** (пробел): блок скрыт	Article
B12	Сравнения (ссылки на пары из белого списка и кураторские наборы)	динамика	раздел 7	своя	пересборка	скрыт	—
B13	Рядом (объекты в радиусе, расстояние в метрах)	динамика	таблица near	своя + OSM / GeoNames (атрибуция)	пересборка после импорта	скрыт	—
B14	Приглашение пройти скрининг (EVT_GOTO_QUIZ)	статика	docs/12	своя	—	всегда	—

6.2 Состав блоков по типам (● обязателен, ○ если есть данные)

Тип	B01	B02	B03	B04	B05	B07	B08	B09	B10	B12	B13	B14
Страна, город	●	●	●	●	●	○	●	○	●	○	○	●
Вуз, колледж, школа	●	○	●	●	○	○	○	—	●	○	○	●
Направление, сфера, профессия	●	●	●	●	—	○	○	○	●	—	—	●
Комбинации T20–T27	●	●	●	●	○	○	○	○	●	○	○	●
Короткая программа (T11/T27)	●	○	●	●	○	○	○	—	●	—	○	●
Геостраницы T50–T54	●	●	●	●	—	—	●	○	●	—	●	●
Сравнения T40–T42	●	—	таблица различий	—	—	—	вердикт	—	●	—	—	●

Считаются только блоки с данными (B03, B04, B05, B07, B09, B13); K_blocks = 4 означает, что при наличии менее четырёх таких блоков страница не индексируется (остаётся оболочкой).

6.3 Оболочка

Что видит посетитель на странице «Обучение из Казахстана в Германию: IT, бакалавриат», когда программ мало: заголовок; форма «подобрать» с предзаполненными полями (B02); честная строка «Под эти условия программ пока нет»; до трёх подсказок «ослабь условие» с числом результатов (механика уже есть в ДС §3.4) — но, в отличие от ДС, подсказки должны уметь снять и «Что у тебя сейчас», и уровень, и направление (ДС §8.3: «9 классов + Германия» — тупик; замечание filters-vs-dev-tree.md §6 п.2); соседние варианты из реальных данных (Германия, другое направление; Австрия, то же направление); срок подачи страны (B05), если календарь есть; приглашение на скрининг (B14).

Что видит робот: 200, noindex, follow, canonical на себя, текст построен из реальных агрегатов; страницы нет в sitemap.

Чем полезна: ведёт посетителя в выдачу /find, показывает альтернативы и собирает спрос: показы и клики по оболочкам — метрика отбора (9.6). Ист.: ВЛ-4, ДС §3.4, П.

7. Сравнения

7.1 Виды

Вид	Что это	Создание	Индексация по умолчанию
(а) Пара «A или B»	вузы, программы, страны, города одного типа	только для k_pair ближайших соседей каждой сущности	noindex; в индекс — белый список (R-7.6)
(б) Набор 3–5 по фильтрам	совпадение по бюджету, городу, стране, направлению, языку, форме; могут быть из разных городов и стран	только для кураторского фильтра или спросовой записи, как «кураторские фасетные посадочные» (ПС §2)	noindex, в индекс — по порогу R-7.6
(в) Подборка из выбора пользователей	агрегат лайков и закладок	после N_agg независимых пользователей	**заблокирован** до решения R-7.14

7.2 Требования

Код	Требование	Критерий	Ист.
R-7.1	Размер набора ≤ 5; шестой и далее отклоняется	набор из 6 → 400	ВЛ-7, АГ
R-7.2	Сущности одного типа	смешанный набор → 404	АГ
R-7.3	Канонический адрес /compare/{type}/{slug1}-{id1}-vs-{slug2}-{id2}[-vs-…] (как slug-id у остальных типов, ПС B3): порядок определяется по возрастанию id; неверный порядок или устаревший слаг → 301 на канонический	все перестановки набора дают один адрес, остальные 301	АГ, ПС
R-7.4	Отбор без n^2: для каждой сущности создаются пары только с её k_pair ближайшими. Близость — только факты базы: пересечение направлений, один регион, близкий ценовой диапазон	число пар ≤ n·k_pair (для 1 785 сущностей ≤ 8 925)	АГ, ПС (04-product: строки только из фактов)
R-7.5	Уникальные блоки: таблица различий (только отличающиеся строки), «что общего», «кому подходит» по фактам, разница цены, срока, языка, срока подачи; доля текста, повторяющего карточки, ≤ 50 %	автотест на выборке	АГ, П
R-7.6	Индексация: оба объекта индексируемы **и** ≥ 80 % ключевых ячеек заполнены **и** (пара в кураторском списке **или** набрала спрос по измеримому показателю). Измеримые показатели для страниц, закрытых от индекса: переходы по внутренней ссылке «сравнить» в карточках, клики по оболочке из формы (аналитика портала); показы вебмастера доступны только после пробного допуска. **Пробный допуск:** до 5 % кандидатов типа (но не более C_pair) получают index на 60 дней без попадания в белый список; по итогам решение по порогам R-9.6. Потолок индексируемых пар — C_pair	0 страниц ниже порога в sitemap; число индексируемых пар ≤ C_pair	АГ, П

Код	Требование	Критерий	Ист.
R-7.7	Вердикт — без рейтинга людей и учреждений: только факты базы (рейтингов в данных нет); оценочные суждения о школах и людях запрещены	осмотр	docs/05
R-7.8	Ячейка без данных — «информации нет», не пустота	—	ПС 04-product

7.3 Подборки из выбора пользователей (вид в)

Код	Требование	Критерий
R-7.9	Публичная страница не содержит идентификаторов, имён, сессий, школы и класса пользователя	поиск по HTML и API не находит полей
R-7.10	Порог: подборка публикуется при N_agg = 50 независимых пользователей. Обоснование: для анонимности достаточно 10–20, но аудитория 10–18 лет, а сущности редкие; запас на потерю при очистке от накрутки	при 49 страницы нет, при 50 есть
R-7.11	Показывается «50+», не точное число; страница публикуется через 7 дней после достижения порога; внутренний счётчик не раскрывается	точных чисел в HTML нет
R-7.12	Независимость: пользователь учитывается один раз на сущность за всё время; повторный голос заменяет прежний, не прибавляется; не более одного изменения в сутки	тест
R-7.13	Антифрод: лимит голосов с устройства и адреса; игнор голосов аккаунтов младше 7 дней; пометка резкого роста; ручной сброс	1 000 голосов с одного адреса агрегат не меняют
R-7.14	**Блокер.** Независимость требует идентификации, то есть данных ребёнка. Принятое решение SEO-платформы: ПДн не собираем, кабинета нет (seo-platform/01-model-ia.md §3); при этом основной продукт данные детей 10–18 лет собирает и требует правовой проработки (docs/05 п.1). Подборки от пользователей вида в смешивают оба контура. Вид в не включается, пока юрист не ответит по согласию законного представителя, юрисдикциям СНГ и MENA и сроку хранения (пробел)	решение записано в разделе 15

Подборки без идентификации (счётчик без аккаунта) не дают независимости и защиты от накрутки, поэтому не заменяют R-7.14.

8. Геопривязка (модель сейчас, генерация по этапам)

Код	Требование	Ист.
R-8.1	Сущности E13–E15 (3.2); отношение «рядом» хранится предрасчитанной таблицей near(a, b, dist_m, rank), пересборка после каждого импорта	АГ
R-8.2	Расстояние — по формуле гаверсинуса между центроидами; маршрутизация не нужна. Радиусы из 5.1	АГ, П
R-8.3	Источники: Wikidata (CC0) — идентификаторы и названия; GeoNames (CC-BY 4.0) — города и административные единицы, ссылка на источник на /o-dannyh/; OpenStreetMap (ODbL) — улицы, районы, точки, подпись «© OpenStreetMap contributors». Реестр лицензий по таблицам	АГ-данные
R-8.4	Ранжирование объектов по известности: число языковых версий Wikipedia (через Wikidata) в пределах типа; при равенстве — число вузов в радиусе. На странице не более 10 объектов, порядок воспроизводим. Известный перекос: Европа сильнее MENA (B)	АГ
R-8.5	Страница геообъекта создаётся при ≥ G_min = 3 вузов в радиусе; иначе canonical на город	П
R-8.6	Против дублей: объект с названием, совпадающим с городом/районом, и центроидом ближе 500 м к его центроиду не получает страницы — canonical на город. Синонимы (Биг-Бен / Elizabeth Tower) — алиас с 301. Два адреса с одним wikidata_qid недопустимы	АГ
R-8.7	Названия и описания из внешних источников проверяются перед публикацией: правки Wikidata/OSM выше порога трафика идут на ручную проверку (защита от вандализма)	АГ

Код	Требование	Ист.
R-8.8	Массовое создание «вуз у каждой улицы» запрещено: геостраницы по типам E13 (достопримечательность) и E15 (регион) в первую очередь; улицы — последняя очередь	АГ, ВЛ-6

9. Индексация и жизненный цикл

9.1 Статусы

Статус промпта	Статус таблицы page_state	Условие
создана	shell / thin	адрес допустим, порогов нет
доступна	ready	пороги выполнены, H пересборок не накоплено
в sitemap	ready + indexable	выполнено H пересборок подряд
индексируется	indexed	по данным вебмастеров; есть в индексе
снята	noindex / gone	см. 9.5

9.2 Требования

Код	Требование	Критерий	Ист.
R-9.1	Флаг indexable вычисляется функцией от данных (5.1), без ручных исключений, кроме белых списков раздела 7	100 % страниц объяснимы данными	АГ-SEO
R-9.2	Sitemap: шард определяется по (тип, язык, номер); номер присваивается странице при первом включении (заполняется последовательно по S_shard = 10 000) и не меняется; индекс файлов; в нём только страницы с indexable; отсюда доля индексации по шарду сопоставима во времени	расхождение sitemap и page_state = 0; файлов на тип и язык не меньше ceil(N/10 000)	АГ-разработка, АГ-SEO
R-9.3	Каждый URL в sitemap отдаёт 200, индексируем, canonical на себя	автотест	АГ
R-9.4	Canonical: self на индексируемых; фильтры, сортировки, page — на базу	—	ПС, ДС
R-9.5	Порядок снятия: убрать из sitemap и перелинковки → noindex (200) → 301 на эквивалент или 410. Disallow в robots до деиндексации запрещён. Журнал стадий на каждый URL	журнал	АГ-SEO
R-9.6	Страница в индексе без показов за W_age = 90 дней снимается. Для страниц, закрытых от индекса (оболочки, пары), спрос измеряется внутренними показателями (клики по оболочке из формы, переходы по ссылке «сравнить», показы после пробного допуска R-7.6); оболочка с показателями выше порога типа — кандидат в материализацию. Порог задаёт владелец (O-5)	таблица 12	docs/12, П
R-9.7	lastmod = дата изменения хэша данных страницы; в хэш входят только блоки B03, B04, B05, B07 (перелинковка B10 и «рядом» B13 не входят); при пересборке без изменений не меняется	автотест	АГ-SEO
R-9.8	robots.txt: Disallow только /api, /account, служебное и метки; Clean-param (Яндекс) только для трекинговых меток (utm_*, gclid, yclid). Тест: ни один URL с noindex не попал под Disallow	тест	ПС, БМ
R-9.9	Микроразметка: BreadcrumbList и тип сущности обязательны; FAQPage — только по видимому на странице вопросу и ответу. Польза FAQPage в выдаче Google ограничена (П: общее знание, проверить)	JSON-LD совпадает с текстом	БМ, АГ

Код	Требование	Критерий	Ист.
R-9.10	hreflang для en/ru (первый выпуск; основной язык en, порядок и ограничения — docs/24): взаимный, с x-default, в sitemap; подкаталоги. kk, uz, ar — noindex и без hreflang, пока переведено < 90 % обязательных блоков. Локаль публикуется только с переводом, а не копией текста другой локали (проверка при приёмке). Региональные варианты (ru-KZ) не делаем	100 % обратных ссылок	АГ, П
R-9.11	Пагинация: страницы 2+ noindex, follow, вне sitemap; каждая сущность достижима за ≤ 3 перехода без пагинации; «Показать ещё» дублируется <a href>	—	ПС
R-9.12	Материализованная индексируемая страница без входящих внутренних ссылок — ошибка сборки; оболочки и пары класса B из проверки исключены	автотест	ПС
R-9.13	Два профиля вебмастера (Яндекс, Google); доля индексации по шарду отдельно. В MENA и Казахстане ведущий Google (П, проверить)	отчёт	АГ-SEO

9.3 Что взято у конкурентов

Параметры не закрываем (правило ПС) — схему Skyscanner/Aviasales не берём, кроме Clean-param для меток; шаблон страницы по насыщенности — от Skyscanner (8–20 блоков, БМ comparison-table.md §9 п.4); небольшой индекс на маршрутах — от Aviasales; тематические подборки как основа индекса Booking — только в виде кураторского слоя.

10. Данные и интеграции

Источник	Что даёт	Лицензия / условия	Обновление	Сверка
База и код портала	сущности E01–E10, программы, цены, календарь, курсы	своя	импорт; курсы не старше 72 ч (ДС)	при каждом импорте
Wikidata	идентификаторы, названия, число языковых версий	CC0	раз в квартал	запись fetched_at
GeoNames	города, административные единицы	CC-BY 4.0, ссылка на /o-dannyh/	раз в квартал	—
OpenStreetMap	улицы, районы, точки	ODbL, share-alike; отдельный слой	раз в полгода	—
O*NET, ESCO	профессии	по правилу данных CLAUDE.md	по правилу	—
api.hh.ru	рынок труда РФ	по условиям hh	по правилу	—
Партнёрские API конкурентов	—	данные в портал не копируются	—	—
MENA	школы, короткие программы	**источники не найдены**, пробел	—	—

R-10.1 Страница /o-dannyh/ перечисляет источники, лицензии и даты сверки (требование P3 02-pseo распространяется на все типы). В репозитории нет парсеров страниц Booking, Skyscanner, Aviasales. **R-10.2** Просроченные записи помечаются на странице «сверено {дата}».

11. Нагрузка и генерация

Код	Требование	Умолчание	Критерий
R-11.1	Серверный рендеринг на Rust с кэшем; весь текст страницы в ответе без JS	—	тест на отключённый JS
R-11.2	Три класса: A — материализованы (в sitemap); B — рендер по запросу с кэшем (noindex); C — оболочка (200, noindex). Каждая страница в одном классе	в A — только страницы, прошедшие раздел 5	—
R-11.3	Таблица page_state(path_hash, type, key, state, n_items, indexable, data_version, etag, rendered_at, last_bot_hit) и page_dep(path_hash, entity_id); журнал переходов	—	переходы только по правилам
R-11.4	Кэш: ключ = путь + язык + data_version; cookie market, currency и «Откуда» (ДС §2) в ключ не входят. Индексируемая страница всегда отдаётся в валюте страны страницы и без «N ч лёта»; персонализация (валюта рынка, перелёт) подгружается отдельным запросом (HTMX) после загрузки. Инвалидация по page_dep; мягкое устаревание (отдать старое, пересобрать в фоне)	TTL 24 ч; цель: через 1 ч после импорта устаревших страниц 0	один и тот же ответ боту и посетителю из любой страны
R-11.5	Очереди: P0 — снятие, 301, noindex; P1 — страницы с показами; P2 — изменённые материализованные; P3 — хвост. Порядок: сущности → агрегаты → комбинации → сравнения. Дубли склеиваются по page_key	8 воркеров	P0 выполняется раньше любой P3
R-11.6	Пределы: 1 000 записей глубины, 50 значений на фильтр, 24 карточки на страницу (ДС); расхождение «20 карточек в каталоге вузов / 24 в остальных» привести к 24 (решение — раздел 15)	24	—
R-11.7	Защита от перебора: любой slug проверяется по множеству сущностей в памяти — нет в нём → 404 без запроса к базе и без рендера, 404 кэшируется на CDN (сброс ключа при создании сущности); оболочка «из A в B» создаётся, только если пара есть в allowed_pair; пары сравнения вне белого списка — класс B со ссылками с подписью HMAC; лимит запросов на адрес и сеть; проверка Googlebot и Яндекс-бота обратным DNS	10 запросов/с на адрес	100 % запросов к несуществующему slug → 404 без обращения к базе
R-11.8	Мониторинг: доля 5xx; доля попаданий в кэш; глубина очередей P0–P3; возраст старейшей P1; доля 404; расхождение sitemap и page_state; число thin в sitemap (цель 0); отставание data_version от импорта; нагрузка ботов	—	оповещения
R-11.9	Единая машина — единая точка отказа (06-operations.md, Ф); CDN перед ней обязательна	—	—

Формулы: время полной сборки $T = N/(W \cdot r)$; нагрузка на источник $origin_rps = (обходов_в_день/86\,400) \cdot (1 - h)$, на холодном хвосте $h \approx 0$; объём $S = N_{mat} \cdot размер_html_gz$ (П: 50 КБ). Примеры в 5.4.

12. Метрики и решения («метрика → порог → действие», по docs/12)

Метрика	Источник	Порог (П)	Действие	Такт
Доля индексации шарда (в индексе / в sitemap)	вебмастера	< 50 % через 60 дней	ревизия шаблона и порогов шарда; подъём P_prog, U_facts	месяц
Показы страницы за 90 дней	вебмастера	0	снятие (9.5)	месяц
Показы и клики оболочки	вебмастера, аналитика	> порога по типу (задаёт владелец, пробел)	кандидат в материализацию	месяц
Доля thin в sitemap	page_state	> 0	остановка выгрузки шарда	сутки
CTR страницы → EVT_GOTO_QUIZ	аналитика	порог по docs/12	чинить блок B14 / текст	2 раза в неделю
Всплеск 404	логи	> 3× от 7-дневного фона (П)	оповещение; разбор перебора	сутки

Метрика	Источник	Порог (П)	Действие	Такт
Доля 5xx	мониторинг	> 1 %	откат пересборки	сутки

Эксперименты: сравнение шардов с разными P_prog (например 3 и 5), метрика — доля индексации через 60 дней; пересмотр порогов раз в месяц по показам.

13. Объём первого выпуска и очерёдность

13.1 Очерёдность

Этап	Что	Условие входа
1. Справочные	T01–T11 (без школ и коротких программ до наличия данных), оболочки T30 только для допущенных пар	данные Сергея; запрос Г выполнен
2. Комбинации	T20–T23, T27, затем T24–T26	выполнены пороги; ≥ 60 дней показов этапа 1
3. Сравнения	вид а (белый список) и б (кураторские)	этап 2 даёт показы; вид в — после R-7.14
4. Геопривязка	E13, E15 → затем E14	G_min, юрист по ODbL

13.2 Первый выпуск: обязательно / вручную / после

Обязательно	Вручную (куратор)	После
T01–T09, T20–T23, оболочки T30 для допущенных пар, sitemap-шарды, page_state**, правила 404/301,** /o-dannyh/	наборы вида б, белый список пар, тексты B08 для стран и городов	T24–T26, T50–T54, вид в, kk/uz/ar, T11 и T12 в индекс

13.3 Зависимости от портала Сергея

Что нужно	Есть?	Владелец	Обход
Страница программы (T06) и список всех слагов в памяти	в разобранных файлах нет	разработка портала	до появления программы показываются карточками на странице вуза
Сущности «школа», «короткая программа»	нет	разработка портала	загрузка провайдерами, noindex до проверки
Гео-справочники, координаты	нет	разработка портала / данные	загрузка Wikidata + GeoNames
История цен и сроков	нет (только курсы 72 ч)	разработка портала	блок B06 не строится
Журнал статей	нет	контент	блок B11 скрыт
Таблица page_state**,** allowed_pair**,** near	нет	разработка портала	—
Переводы kk, uz, ar	не подтверждены	контент	noindex для локалей
Исправление дефекта #268 («Найти» теряет фильтры) и тупика «9 классов + Германия»	открыты (ДС, filters-vs-dev-tree.md §6)	разработка портала	оболочки не опираются на /find до исправления

14. Критерии приёмки (сквозные сценарии)

№	Сценарий	Ожидаемый результат
1	Запрос /from/xx/to/de/fields/it/bachelor для существующих сущностей и допущенной пары, программ меньше порога	200, noindex, форма предзаполнена, в sitemap нет
2	Тот же адрес с несуществующей страной	404 без обращения к базе
3	Импорт добавил программы, порог выполнен, две пересборки подряд	страница ready, в sitemap, lastmod обновлён
4	Пересборка без изменений данных	lastmod не меняется
5	/compare/university/42-vs-17	301 на /compare/university/17-vs-42
6	Набор из шести объектов; набор из вуза и программы	400; 404
7	Для 1 785 сущностей и k_pair = 5	пар создано от 4 463 до 8 925; индексируемых ≤ 1 785
8	Голосов за подборку 49 / 50 (после снятия R-7.14)	страницы нет / появляется через 7 дней после 50-го; в HTML «50+»
9	Автотест robots.txt	ни один noindex-URL не под Disallow
10	Объект «Биг-Бен» и алиас «Elizabeth Tower»	один адрес, алиас → 301
11	Объект с названием города на расстоянии < 500 м от центроида	canonical на город
12	Локаль ar при переводе 60 % блоков	noindex, hreflang нет
13	Всплеск 1 000 запросов к несуществующим slug	404 с CDN, нагрузки на базу нет, оповещение
14	Просмотр HTML публичной подборки	нет идентификаторов пользователя
15	Фильтры: IT, Германия, бакалавриат, английский, бесплатно	один постоянный адрес /p/de/it/bachelor/en/free; ответ одинаков для человека и робота; в HTML нет идентификаторов пользователя
16	Мультивыбор языков (английский и немецкий)	постоянного адреса нет, остаётся /find, noindex
17	Тот же набор, что у T20 (страна + направление)	один адрес T20, адреса T43 нет

15. Открытые решения

№	Вопрос	Владелец (направление)	Срок «до чего»	Умолчание	Цена ошибки
O-1	Согласие законного представителя, юрисдикции СНГ и MENA, срок хранения для вида в	юрист; продукт	до включения вида в	вид в выключен	нарушение закона о данных несовершеннолетних, docs/05
O-2	Лицензионный режим ODbL при хранении OSM рядом с базой	юрист; данные	до подключения OSM	отдельный слой	раскрытие базы под share-alike
O-3	Пороги P_prog, U_facts, U_text, k_pair, N_agg	SEO; владелец	до начала генерации	таблица 5.1	мусор в индексе или недобор страниц
O-4	Какие локали публикуются в первом выпуске	контент; владелец	до включения в sitemap	ru, en	дубли и «малоценный контент»
O-5	Порог внутреннего показателя спроса для белого списка пар и материализации оболочек (R-7.6, R-9.6)	SEO	до включения в sitemap	10 кликов по оболочке или ссылке «сравнить» за 90 дней	накрутка белого списка либо пустой белый список

№	Вопрос	Владелец (направление)	Срок «до чего»	Умолчание	Цена ошибки
O-16	Граница D1 для страниц-сущностей: какие поля вуза, школы и программы считаются «идентичностью» и разрешены в HTML	владелец; разработка портала	до начала генерации T03–T06	название, страна, город, тип, сайт	выдача базы по записям либо пустые страницы без ценности
O-15	Учёт набора по годам (дата набора у программы): без него год набора не даёт отличающихся страниц (R-4.3.9)	разработка портала; продукт	до включения года набора в T43	год не используется как фасет страницы	страницы-дубли или потеря запросов «на 2027»
O-11	Автоматический 301 с /find?... на постоянный адрес допустимой комбинации	разработка портала; SEO	до включения T43 в sitemap	выключено; ссылка «Открыть страницей»	смешанные сигналы поисковикам или потеря интерфейса
O-12	Падежи и формы слов в справочниках для мета-шаблонов (docs/23, M-5)	разработка портала; контент	до начала генерации	страны и языки сразу, города по мере T21	кривые заголовки
O-10	Переименовать публичный параметр riasec в /careers	разработка портала; юрист	до включения T26 и страниц профессий в индекс	work_type	претензия по лицензии на название методики
O-6	Привести 20 карточек в каталоге вузов к 24	разработка портала	до начала генерации	24	расхождение пагинации
O-7	Страница программы (T06): нужна ли отдельной сущностью	продукт; разработка	до этапа 2	нет	потеря запросов «программа X в университете Y»
O-8	Подтвердить ведущий поисковик по MENA и Казахстану	SEO	до этапа 2	Google	потеря охвата
O-9	Пересмотр тезиса «миллиард»: принять потолок 5.4	владелец	до этапа 3	5.4	инвестиции в генерацию без отдачи

16. Разбор красной команды

Проверка независимым субагентом без указания авторства (протокол скилла red-team). Сверка арифметики и цитат — корректна (1 785·1 784/2 = 1 592 220; 20 565 − 16 248 = 4 317; 9·23 = 207; C(1000,5) ≈ 8,25·10^{12}; 10^9/400 ≈ 29 суток).

Претензия	Вердикт	Что изменилось
Критерий спроса замкнут: закрытые от индекса страницы не дают показов	подтверждено	R-7.6, R-9.6: внутренние показатели и пробный допуск; O-5
Кэш и валюта по cookie market	подтверждено	R-11.4: страница в валюте страны, персонализация отдельно
Ложная ссылка на docs/05 **п.1 («не собираем»)**	подтверждено	R-7.14 исправлен: два контура
Пары: n·k/2 неверно, правильно n·k	подтверждено	5.1–5.3, R-7.4, приёмка №7
«1 % сущностей» неясно	подтверждено	параметр C_pair с примером
Пороги относились к созданию, а не к индексации	подтверждено	R-2.5, 5.2; P_short в 5.1
P_prog **считает программы, а не вузы**	подтверждено	добавлено ≥ P_inst

Претензия	Вердикт	Что изменилось
«Вариант Booking» не подтверждён входами	подтверждено	1.2 переписано: основание — логика 02-pseo, расхождение с рекомендацией БМ названо
Шардирование по хэшу ломает диагностику	подтверждено	R-9.2: номер шарда присваивается при включении
Мелкие противоречия (R-7.11/12, R-9.12, canonical оболочки, слои существования и классов)	подтверждено	исправлены; добавлено «Соответствие слоёв» и понижающий гистерезис
K_blocks **считал вечные блоки**	подтверждено	считаются только блоки с данными
Подмена статуса «О» у чисел экрана; «9 рынков» без источника	подтверждено	5.3 переразмечено
Неверные ссылки (ДС §6.2, БМ §9.4, опечатка «22,6 тыс.»)	подтверждено	исправлены
R-7.3: слаг не в адресе	подтверждено	единый подход slug-id
riasec **назван внутренним, а он публичный**	подтверждено	1.3 и О-10
Не закрыто: плотность оболочек, состав хэша lastmod**, уникальность ru/en**	подтверждено частично	N_shell_max, состав хэша в R-9.7; проверка ru/en вынесена в приёмку локали (R-9.10: перевод, не копия)

Спорных и отклонённых претензий нет. Спорное по существу остаётся в разделе 15 (пороги — П, значения подбираются по показам).

17. Проверка по правилам проекта

- Критик, не соглашатель: тезис «миллиард страниц» проверен и признан гипотезой (5.4); прежние решения показаны таблицей противоречий (1.2), не сглажены.
- Названия тестов: BFAS/Big Five и RIASEC в публичных адресах не используются; публичный параметр riasec вынесен в О-10.
- Три цели привлечения экспертов, поток 1 и поток 2: страницы относятся к потоку 2; метрики потоков не смешаны; цифры потока 1 не используются.
- Центральная гипотеза скрининга не использована как основание требований; В14 лишь ведёт на скрининг.
- Правило данных: у внешних блоков источник, лицензия, периодичность (раздел 10); профессии — O*NET и ESCO, рынок труда РФ — api.hh.ru, MENA — пробел (3.3, 10).
- Данные несовершеннолетних: вид в заблокирован до решения юриста (R-7.14, О-1).
- Достоверность: цифры конкурентов даны с пометкой источника из comparison-table.md; объёмы базы портала не выдуманы — формулы и запрос Г; пороги помечены П.
- Язык: русский; допущены общепринятые термины (canonical, sitemap, hreflang, noindex).
- Прежние документы не изменены.

Приложение А. Каталог типов страниц

Адреса: существующие в портале сохраняются (ДС); новые — предложение (П). Язык: префикс /{lang}/ для не основных (П).

Код	Тип	Шаблон адреса	Условие создания	Условие индексации	Canonical	Пустое состояние
T01	Страна	/countries/{cc}	страна есть	≥ 1 программа, K_blocks	self	оболочка
T02	Город	/universities/{cc}/{город}	в городе есть вуз или школа	как T01	self	оболочка
T03	Вуз	/universities/{slug-id} (П)	всегда	K_blocks	self	noindex
T04	Колледж	/colleges/{slug-id}	всегда	K_blocks	self	noindex
T05	Школа	/schools/{slug-id} (П)	запись проверена	K_blocks, возраст и тип заполнены	self	noindex
T06	Программа	/programs/{id} (П, О-7)	решение О-7	K_blocks	self	—
T07	Направление	/fields/{slug}	есть	≥ P_prog	self	оболочка
T08	Сфера	/spheres/{slug}	есть	как T07	self	оболочка
T09	Профессия	/careers/{slug}	есть	K_blocks, U_text	self	noindex
T10	Олимпиада	/olympiads/{slug} (П)	только ru	K_blocks	self	noindex
T11	Короткая программа	/short/{slug-id} (П)	запись проверена	поля E11 заполнены, дата в будущем	self	снятие после даты
T20	Направление×страна	/fields/{slug}/{cc} (П)	≥ 1 программа	≥ P_prog и ≥ P_inst	self	оболочка
T21	Направление×город	/fields/{slug}/{cc}/{город}	≥ 1 вуз	≥ P_inst	self	оболочка
T22	Уровень×страна	/{cc}/level/{level}	≥ 1 программа	≥ P_prog и ≥ P_inst	self	оболочка
T23	Язык×страна	/{cc}/lang/{lang}	≥ 1 программа	≥ P_prog и ≥ P_inst	self	оболочка
T24	Форма×город	/{cc}/{город}/form/{form}	≥ 1	≥ P_inst и спрос	self	noindex
T25	Бюджет до X×страна	/{cc}/budget/{band}	≥ 1	≥ P_prog и ≥ P_inst	self	noindex
T26	Профессия → где учиться	/careers/{slug}/study/{cc}	≥ 1	≥ P_prog и ≥ P_inst	self	noindex
T27	Короткие программы: тема×страна×период×возраст	/short/{topic}/{cc}/{period}/{age} (П)	≥ 1 актуальная	≥ P_short	self	снятие после периода
T31	Хаб страны отправления	/from/{cc} (П)	страна — рынок портала	режим контента: ≥ 6 блоков, R-4.4.5	self	noindex
T30	Маршрут «из X в Y»	/from/{cc1}/to/{cc2} (П)	allowed_pair (булево)	режим контента: R-4.4.4, R-4.4.5	self	оболочка
T40	Пара «A или B»	/compare/{type}/{idA}-vs-{idB}	k_pair-соседи	белый список (R-7.6)	self	noindex
T41	Набор 3–5	/compare/{type}/{id1}-vs-{id2}-vs-{id3}…	кураторский фильтр	по порогу R-7.6	self	noindex
T42	Подборка из выбора	/picks/{id} (П)	N_agg, R-7.14	после снятия блокера	self	не создаётся
T43	Страница из выбранных фильтров (режим контента)	/from/{cc1}/to/{cc2}/{направление}/{уровень}/{язык}/{год} (П); без страны отправления — /to/{cc2}/…	допустимый набор фасетов из R-4.3.3	пороги раздела 5	self	оболочка noindex

Код	Тип	Шаблон адреса	Условие создания	Условие индексации	Canonical	Пустое состояние
T50	Достопримечательность	/places/{slug-id}	≥ G_min вузов в радиусе	как условие	self	canonical на город
T51	Район / улица	/places/{slug-id}	как T50	как T50, R-8.8	self	canonical на город
T52	Природный регион	/regions/{slug-id}	≥ G_min	как T50	self	—
T53	«Вуз у объекта»	/near/{place-slug-id}/universities	≥ G_min	как T50	self	—

Приложение Б. Пять образцов страниц

1. Оболочка «Из Казахстана в Германию: IT, бакалавриат» (T30). H1 по шаблону; блоки B02 (форма), B03 (факты Германии: число программ, вилка цен), B05 (календарь), B04 (программы соседних уровней, если есть), B10 (Австрия, Нидерланды — те же поля), B14. Источники: база портала. Состояние: shell.

2. Страна × направление (T20): «IT в Германии». B01, B02, B03 (число программ, языки, цены, бесплатные места), B04 (24 карточки), B05, B07 (FAQ из агрегатов), B08 (текст о направлении в стране, редакция), B09 (подборки редактора), B10 (город×направление, соседние страны), B12, B14. Состояние: indexed.

3. Вуз у достопримечательности (T53): «Университеты у Британского музея». B01, B02, B04 (вузы в радиусе 5 км, расстояние в метрах), B13, B08 (описание объекта: основа — Wikidata + редакция), B10, B14. Источники: база, OSM (ODbL, атрибуция), Wikidata (CC0). Состояние: вторая очередь.

4. Сравнение «A или B» (T40). B01; таблица различий (цена, срок, язык, срок подачи, города); «что общего»; «кому подходит» по фактам; ссылки на карточки и на соседние пары. Источники: база. Состояние: noindex, пока не в белом списке.

5. Набор 3–5 (T41): «IT в Европе до 5 000 € в год». Список 3–5 вариантов из разных стран, таблица различий, критерии выбора. Источник: кураторский фильтр. Состояние: noindex, в индекс — по R-7.6.

Приложение В. Прослеживаемость

Источник	Что дал
ВЛ-1…ВЛ-7 (12.11.2026)	разделы 1, 3.2, 4, 7, 8
ДС (дерево фильтров, 12.11.2026)	адреса, параметры, пределы, индексация /find, механика пустой выдачи, дефекты (#268 и др.)
БМ (бенчмарк)	масштабы, состав блоков, robots/noindex, микроразметка
ПС (июль 2026)	пороги, слаги, канонизация, жизненный цикл, модель «ступица и спицы»
АГ-SEO, АГ-данные, АГ-сравнения, АГ-разработка	пороги, лицензии, схема антифрода, схема кэша и очередей. Всё — предложение (П) до подтверждения
docs/05, docs/12	данные подростков, цикл «метрика → порог → действие», EVT_GOTO_QUIZ

Приложение Г. Запрос подсчёта объёма (П; имена таблиц условные)

```sql
WITH cf AS ( -- вузы по городу и направлению
SELECT i.city_id, p.field_id, count(DISTINCT p.inst_id) n_inst, count(*) n_prog
FROM program p JOIN entity i ON i.id = p.inst_id
GROUP BY 1, 2),
cc AS ( -- программы по стране и направлению
SELECT i.country_iso2, p.field_id, count(*) n_prog
FROM program p JOIN entity i ON i.id = p.inst_id
GROUP BY 1, 2),
ci AS ( -- вузы по городу
SELECT city_id, count(*) n
FROM entity WHERE type = 'institution'
GROUP BY 1)
SELECT 'entities' AS metric, count(*) AS value FROM entity
UNION ALL SELECT 'city_field_all', count(*) FROM cf
UNION ALL SELECT 'city_field_ge_Pinst', count(*) FILTER (WHERE n_inst >= :p_inst) FROM cf
UNION ALL SELECT 'country_field_all', count(*) FROM cc
UNION ALL SELECT 'country_field_ge_Pprog', count(*) FILTER (WHERE n_prog >= :p_prog) FROM cc
UNION ALL SELECT 'pairs_all_same_city', COALESCE(sum(n*(n-1)/2), 0) FROM ci;
```

Выполнить одним обращением; результат вписать в 5.2 вместо формул.